

# Taller de Preparación – Certificación Apache Spark Cloudera 2021

Este taller forma parte del programa Data Engineering dictado por Datahack, y del curso de Apache Spark

### Iniciamos los servicios de Hadoop y YARN:

```
• HDFS - start-dfs.sh
```

• YARN - start-yarn.sh

### Copiamos los ficheros que usaremos en nuestra práctica

```
hdfs dfs -put /data/retail_db /public
hdfs dfs -ls /public/retail_db

http://www.datahack.la
```

## **Ejercicio 1:**

### Origen:

Convertir un archivo csv en avro y almacenarlo en una ruta de HDFS

hdfs: /public/retail\_db/orders/

#### Resultado:

Almacena la información en: /user/vagrant/lab1/pregunta1/resultado

Con el siguiente esquema:

```
orders

order_id: int
order_date: date

order_customer_id: int
order_status: string
```



# 1. Respuesta - Spark Scala:

Requerimiento: spark-shell --packages org.apache.spark:spark-avro\_2.11:2.4.4

```
import org.apache.spark.sql.types._

val customSchema = StructType(Array(
    StructField("order_id", IntegerType, true),
    StructField("order_date", DateType, true),
    StructField("order_customer_id", IntegerType, true),
    StructField("order_status", StringType, true))
)

val orders = spark.read.format("csv").option("inferSchema",
    "true").schema(customSchema).load("/public/retail_db/orders")

orders.write.format("avro").save("/user/vagrant/lab1/pregunta1/orders_avro")

http://www.datahack.la
```

```
val validate =
spark.read.format("avro").load("/user/vagrant/lab1/pregunta1/result
ado/part-00000-cdedfeca-66a3-43de-a6cf-318d13780da8-c000.avro")

validate.printSchema()
validate.count()
validate.show()
http://www.datahack.la
```

# 1. Respuesta - Pyspark:



### Requerimiento: pyspark --packages org.apache.spark:spark-avro\_2.11:2.4.4

```
from pyspark.sql.types import *

customSchema = StructType([
    StructField("order_id", IntegerType(), True),
    StructField("order_date", DateType(), True),
    StructField("order_customer_id", IntegerType(), True),
    StructField("order_status", StringType(), True)
    ])

orders = spark.read.option("inferSchema",
"true").schema(customSchema).csv("/public/retail_db/orders")

orders.write.format("avro").save("/user/vagrant/lab1/pregunta1/orders_avro")

http://www.datahack.la
```

```
validate =
spark.read.format("avro").load("/user/vagrant/lab1/pregunta1/result
ado ")
validate.printSchema()
validate.count()
validate.show()
http://www.datahack.la
```

# **Ejercicio 2:**



#### Origen:

Convertir un archivo csv en parquet y almacenarlo en una ruta de HDFS

hdfs: /public/retail\_db/customers/part-00000

#### Resultado:

Almacena la información en: /user/vagrant/lab1/pregunta2/resultado

Con el siguiente esquema:

customer

+ customer\_id: int

+ customer\_fname: string

+ customer\_lname: string

+ customer\_email: string

+ customer\_password: string

+ customer\_password: string

+ customer\_street: string

+ customer\_state: string

+ customer\_city: string

+ customer\_zipcode: string

# 1. Respuesta - Spark Scala:

```
val customerSchema = StructType(Array(
   StructField("customer_id", IntegerType, true),
   StructField("customer_fname", StringType, true),
   StructField("customer_lname", StringType, true),
   StructField("customer_email", StringType, true),
   StructField("customer_password", StringType, true),
   StructField("customer_street", StringType, true),
   StructField("customer_state", StringType, true),
   StructField("customer_city", StringType, true),
   StructField("customer_city", StringType, true)
   )
}
```



```
customerSchema = StructType([
   StructField("customer id", IntegerType(), True),
   StructField("customer fname", StringType(), True),
   StructField("customer_lname", StringType(), True),
   StructField("customer email", StringType(), True),
   StructField("customer password", StringType(), True),
   StructField("customer street", StringType(), True),
   StructField("customer state", StringType(), True),
   StructField("customer city", StringType(), True),
   StructField("customer zipcode", StringType(), True)
  ])
customer =
spark.read.schema(customerSchema).csv("/public/retail db/customers/
part-00000")
customer.write.format("parquet").save("/user/vagrant/lab1/pregunta2
/customer")
                                            http://www.datahack.la
```



# **Ejercicio 3:**

### Origen:

Leer la tabla orders en formato avro y aplicar una comprimir en gzip

hdfs:/user/vagrant/lab1/pregunta1/resultado/part-00000-cdedfeca-66a3-43de-a6cf-318d13780da8-c000.avro

#### Resultado:

Almacena la información en: /user/vagrant/lab1/pregunta3/resultado

Con el siguiente esquema: Order\_id, order\_status

# 3. Respuesta - Spark Scala:

Requerimiento: spark-shell --packages org.apache.spark:spark-avro\_2.11:2.4.4

# 3. Respuesta - Pyspark:



# **Ejercicio 4:**

### Origen:

Obtener los clientes que realizaron más de 4 compras

customer: /user/vagrant/lab1/pregunta2/customer

orders: /user/vagrant/lab1/pregunta1/orders\_avro/part-00000-26e036ad-b866-4723-bab3-a450da706f5a-c000.avro

#### Resultado:

Almacena la información en formato JSON: /user/vagrant/lab1/pregunta4/resultado

Con el siguiente esquema y deber ser en orden descendente:

customer\_id, customer\_fname, customer\_Iname, cant

# 4. Respuesta - Spark Scala:

```
val customer =
spark.read.format("parquet").load("/user/vagrant/lab1/pregunta2/cus
tomer")

customer.createOrReplaceTempView("customer")

val orders_avro =
spark.read.format("avro").load("/user/vagrant/lab1/pregunta1/orders
_avro/part-00000-26e036ad-b866-4723-bab3-a450da706f5a-c000.avro")

orders_avro.createOrReplaceTempView("orders_avro")

http://www.datahack.la
```



```
customer =
spark.read.format("parquet").load("/user/vagrant/lab1/pregunta2/cus
tomer")
customer.createOrReplaceTempView("customer")

orders_avro =
spark.read.format("avro").load("/user/vagrant/lab1/pregunta1/orders
_avro/part-00000-26e036ad-b866-4723-bab3-a450da706f5a-c000.avro")

orders_avro.createOrReplaceTempView("orders_avro")

result = spark.sql("select customer_id, customer_fname,
customer_lname ,count(*) as cant from customer a inner join
orders_avro b on a.customer_id = order_customer_id group by
customer_id, customer_lname, customer_fname having count(*) > 5 ")

result.sort(result.cant.desc()).write.format("json").save("/user/vagrant/lab1/pregunta4_python/resultado")

http://www.datahack.la
```



## **Ejercicio 5:**

### Origen:

Obtener el máximo precio de los productos.

```
products: /public/retail_db/products/part-00000
```

### Resultado:

Almacena la información en formato text, comprimido en gzip y solo deberá ser un solo file.

## /user/vagrant/lab1/pregunta5/resultado

El archivo deberá ser almacenado de la siguiente manera

```
Product id | product_price
145787 | 100.0
```

### 5. Respuesta - Spark Scala:

```
val ProductSchema = StructType(Array(
  StructField("product id", IntegerType, true),
  StructField("product_category_id", IntegerType, true),
  StructField("product_name", StringType, true),
  StructField("product description", StringType, true),
  StructField("product price", FloatType, true),
  StructField("product image", StringType, true)
val product = spark.read.format("csv").option("inferSchema",
"true").schema(ProductSchema).load("/public/retail db/products/part
-00000")
product.createOrReplaceTempView("product")
val result =spark.sql("select product id, max(product price) as
max price from product group by product id")
result.createOrReplaceTempView("result")
val result2 =spark.sql("select concat(product id, '|', max price)
as data from result ")
```



```
result2.repartition(1).write.option("compression","gzip").format("text").save("/user/vagrant/lab1/pregunta5/resultado")

http://www.datahack.la
```

```
ProductSchema = StructType([
   StructField("product id", IntegerType(), True),
   StructField("product category id", IntegerType(), True),
   StructField("product name", StringType(), True),
   StructField("product description", StringType(), True),
   StructField("product price", FloatType(), True),
   StructField("product image", StringType(), True)
   1)
product = spark.read.format("csv").option("inferSchema",
"true").schema(ProductSchema).load("/public/retail db/products/part
-00000")
product.createOrReplaceTempView("product")
result =spark.sql("select product id, max(product price) as
max_price from product group by product_id")
result.createOrReplaceTempView("result")
result2 =spark.sql("select concat(product id, '|', max price) as
data from result ")
result2.repartition(1).write.option("compression", "gzip").format("t
ext").save("/user/vagrant/lab1/pregunta5/resultado")
                                            http://www.datahack.la
```



# **Ejercicio 6:**

### Origen:

Obtener los clientes

customer: /user/vagrant/lab1/pregunta2/customer

### Resultado:

Almacena la información en formato text, deberá estar comprimido en bzip2 y con un delimitador "/t"

Concatenar los valores del first\_name (3 caracteres) y last\_name

### /user/vagrant/lab1/pregunta6/resultado

El archivo deberá ser almacenado de la siguiente manera

Customer\_id name, customer\_street

### 6. Respuesta - Spark Scala:

```
val customer =
spark.read.format("parquet").load("/user/vagrant/lab1/pregunta2/cus
tomer")

customer.createOrReplaceTempView("customer")

val result = spark.sql("select customer_id,
    concat(substring(customer_fname,1,3),' ', customer_lname) as name,
    customer_street from customer")

result.map(x =>
x.mkString("\t")).write.option("compression","bzip2").format("text"
).save("/user/vagrant/lab1/pregunta6/resultado")

http://www.datahack.la
```



```
customer =
spark.read.format("parquet").load("/user/vagrant/lab1/pregunta2/cus
tomer")

customer.createOrReplaceTempView("customer")

val result = spark.sql("select customer_id,
concat(substring(customer_fname,1,3),' ', customer_lname) as name,
customer_street from customer")

result.rdd.map(lambda x:
"\t".join(map(str,x))).saveAsTextFile("/user/vagrant/lab1/pregunta6/resultado","org.apache.hadoop.io.compress.BZip2Codec")

http://www.datahack.la
```



# **Ejercicio 7:**

### Origen:

Cargar información de productos al metastore:

product:/public/retail\_db/products/part-00000

#### Resultado:

Almacenar en Metastore table products

7. Respuesta - Spark Scala:

Requerimiento: spark-shell --packages org.apache.spark:spark-avro\_2.11:2.4.4

## 7. Respuesta - Pyspark:

```
product = spark.read.format("csv").option("inferSchema",
"true").schema(ProductSchema).load("/public/retail_db/products/part
-00000")
product.write.format("hive").saveAsTable("product")
http://www.datahack.la
```



# **Ejercicio 8:**

### Origen:

Agrupar cantidad de transacciones por mes utilizando el metastore:

```
orders:/public/retail_db/orders/part-00000
```

#### Resultado:

Almacenar el resultado, en formato parquet sin comprimir en la ruta:

### /user/vagrant/lab1/pregunta8/resultado

El archivo deberá ser almacenado con el esquema

Count, month (format YYYYMM)

## 8. Respuesta - Spark Scala:

```
val orders = spark.read.format("csv").option("inferSchema",
  "true").schema(customSchema).load("/public/retail_db/orders/part-
00000")

orders.write.format("hive").saveAsTable("orders")

val result = spark.sql("select count(*) as
  count,date_format(order_date,'YYYYYMM') as month from orders group
  by date_format(order_date, 'YYYYYMM')")

result.write.option("compression","uncompressed").format("parquet")
  .save("/user/vagrant/lab1/pregunta8/resultado")
```



```
orders = spark.read.format("csv").option("inferSchema",
  "true").schema(customSchema).load("/public/retail_db/orders/part-
00000")

orders.write.format("hive").saveAsTable("orders")

result = spark.sql("select count(*) as
  count,date_format(order_date,'YYYYYMM') as month from orders group
  by date_format(order_date, 'YYYYYMM')")

result.write.option("compression", "uncompressed").format("parquet")
.save("/user/vagrant/lab1/pregunta8/resultado")

http://www.datahack.la
```



# **Ejercicio 9:**

### Origen:

Guardar la información de ítem y transacciones en formato ORC

Order\_items: /user/vagrant/lab1/pregunta9\_2/resultado

#### Resultado:

Almacenar el resultado sin comprimir: /user/vagrant/lab1/pregunta9/resultado

9. Respuesta - Spark Scala:

```
val itemsSchema = StructType(Array(
   StructField("order_item_id", IntegerType, true),
   StructField("order_item_order_id", IntegerType, true),
   StructField("order_item_product_id", IntegerType, true),
   StructField("order_item_quantity", IntegerType, true),
   StructField("order_item_subtotal", FloatType, true),
   StructField("order_item_productprice", FloatType, true))
)

val order_items= spark.read.format("csv").option("inferSchema",
   "true").schema(itemsSchema).load("/public/retail_db/order_items/part-00000")

order_items.write.format("orc").option("compression","uncompressed").save("/user/vagrant/lab1/pregunta9/resultado")

http://www.datahack.la
```



```
itemsSchema = StructType([
    StructField("order_item_id", IntegerType(), True),
    StructField("order_item_order_id", IntegerType(), True),
    StructField("order_item_product_id", IntegerType(), True),
    StructField("order_item_quantity", IntegerType(), True),
    StructField("order_item_subtotal", FloatType(), True),
    StructField("order_item_productprice", FloatType(), True)
])

order_items= spark.read.format("csv").option("inferSchema",
    "true").schema(itemsSchema).load("/public/retail_db/order_items/part-00000")

order_items.write.format("orc").option("compression","uncompressed").save("/user/vagrant/lab1/pregunta9/resultado")

http://www.datahack.la
```



# **Ejercicio 10:**

### Origen:

Obtener información de los clientes top de transacciones en cantidad y monto de consumo que se ubican en ciudades que empiecen con M.

```
customer:/user/vagrant/lab1/pregunta2/customer
order_items: /user/vagrant/lab1/pregunta9/resultado
orders: metaestore table orders
```

#### Resultado:

Almacenar el resultado en formato parquet comprimido en Gzip:

/user/vagrant/lab1/pregunta10/resultado

4. Respuesta - Spark Scala:

```
val customer =
spark.read.format("parquet").load("/user/vagrant/lab1/pregunta2/cus
tomer")

customer.createOrReplaceTempView("customer")

val order_items =
spark.read.format("orc").load("/user/vagrant/lab1/pregunta9/resulta
do")

order_items.createOrReplaceTempView("order_items")

val top_customer = spark.sql("select customer_id, customer_fname,
count(*) as cant, sum(order_item_subtotal) as total from customer
a inner join orders b on a.customer_id = b.order_customer_id inner
join order_items c on c.order_item_order_id = b.order_id where
customer_city like 'M%' group by customer_id, customer_fname")

top_customer.write.format("parquet").option("compression", "gzip").s
ave("/user/vagrant/lab1/pregunta10/resultado")

http://www.datahack.la
```



```
customer =
spark.read.format("parquet").load("/user/vagrant/lab1/pregunta2/cus
tomer")
customer.createOrReplaceTempView("customer")
order items =
spark.read.format("orc").load("/user/vagrant/lab1/pregunta9/resulta
do")
order items.createOrReplaceTempView("order items")
top customer = spark.sql("select customer id, customer fname,
count(*) as cant, sum(order item subtotal) as total from customer
a inner join orders b on a.customer id = b.order customer id inner
join order items c on c.order item order id = b.order id where
customer city like 'M%' group by customer id, customer fname")
top customer.write.format("parquet").option("compression", "gzip").s
ave("/user/vagrant/lab1/pregunta10/resultado")
                                            http://www.datahack.la
```



